ggplot2

Fundamentos lenguajes: R

Alberto Torres e Irene Rodríguez

2019-12-07

Introducción

- Implementa una **gramática de gráficos** en R.
- Divide un gráfico en sus componentes esenciales:
  - Un conjunto de datos.
  - Un conjunto de marcas visuales (puntos, lineas, barras) y propiedades asociadas a ellas (color, tamaño, tipo, etc.).
  - Un sistema de coordenadas.

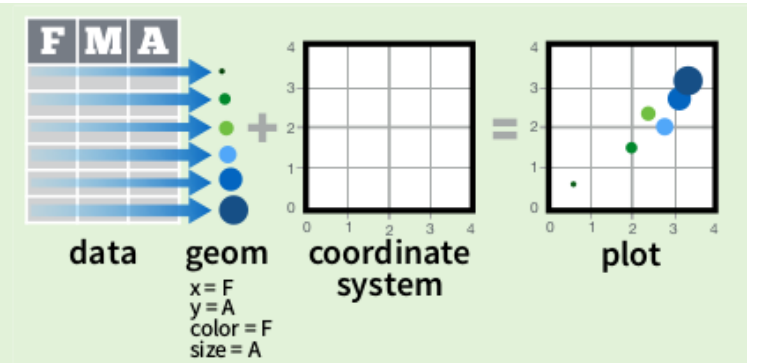

- Múltiples ventajas con respecto a los gráficos de R base
  - Leyenda automática
  - Facetas
  - ...

Introducción (cont.)

- Los capítulos de *data visualization* y *graphics for communication* del libro R for data science son una buena forma de empzar.
- La cheatsheet de ggplot2 es muy útil como resumen, así como la documentación de referencia de ggplot2 que contiene muchos ejemplos.

Gramática de gráficos

- Para generar un gráfico en ggplot, se usan las funciones `qplot()` o `ggplot()`.
    - `qplot()` es una versión simplificada de `ggplot()` que permite definir los datos a representar, coordenadas y la forma en qué se representar (líneas, puntos...), y provee muchos valores por defecto.
- Por su flexibilidad, veremos `ggplot()`.

Gramática de gráficos (cont.)

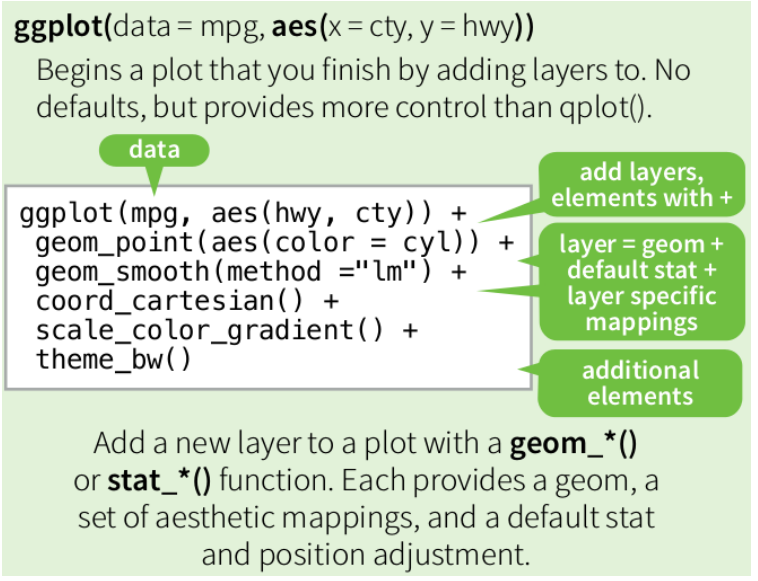

- *data* data frame
- *mapping* se define con `aes()` (*aesthetics*) y describe como las variables de un data frame se asignan a propiedades visuales
- *geom* objetos geométricos con el que se van a representar los datos
- *stat* transforman los datos
- *position* pequeños ajustes en la posición de los elementos

Plantilla

- El gráfico más sencillo consta como mínimo de los siguientes componentes [Fuente]:

```
ggplot(data = <DATA>) +
  <GEOM_FUNCTION>(mapping = aes(<MAPPINGS>))
```

- Cambiando las secciones entre `<>` se pueden crear múltiples tipos de gráficos
- Añadiendo geoms con el operador `+` se pueden crear gráficos compuestos

Ejemplo

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy))
```

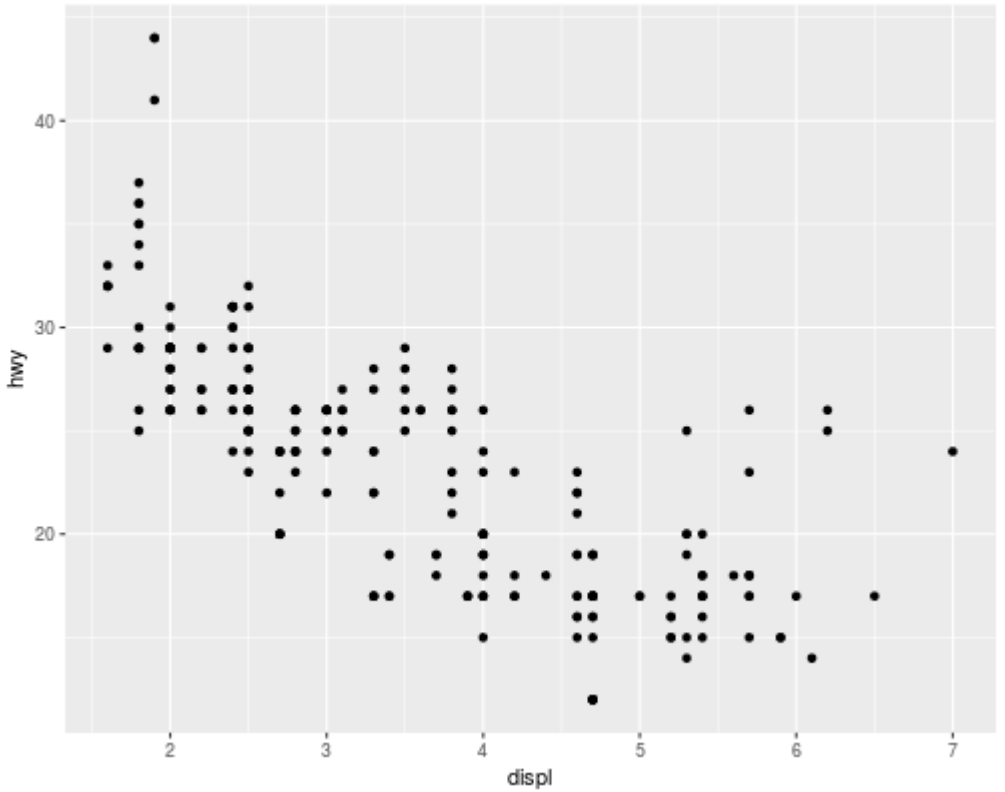

Aesthetics

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy))
```

- El gráfico anterior representa dos variables, `displ` y `cyl`
- Variables adicionales se pueden asignar a distintas propiedades del gráfico (*aesthetics*)
- Algunos ejemplos son `color`, `shape`, `size`, `alpha`, etc.
- La escala y la leyenda se crean de forma automática

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, color = drv))
```

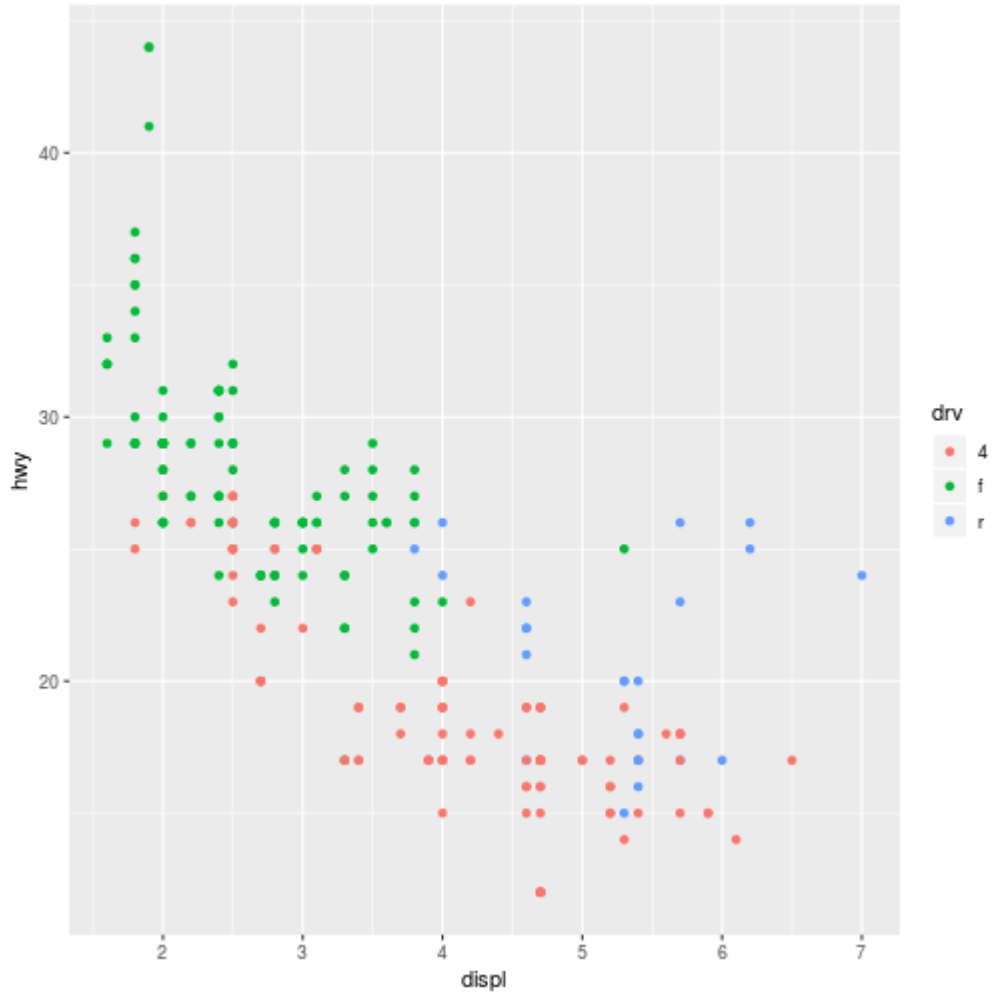

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, color = class, size = cyl))
```

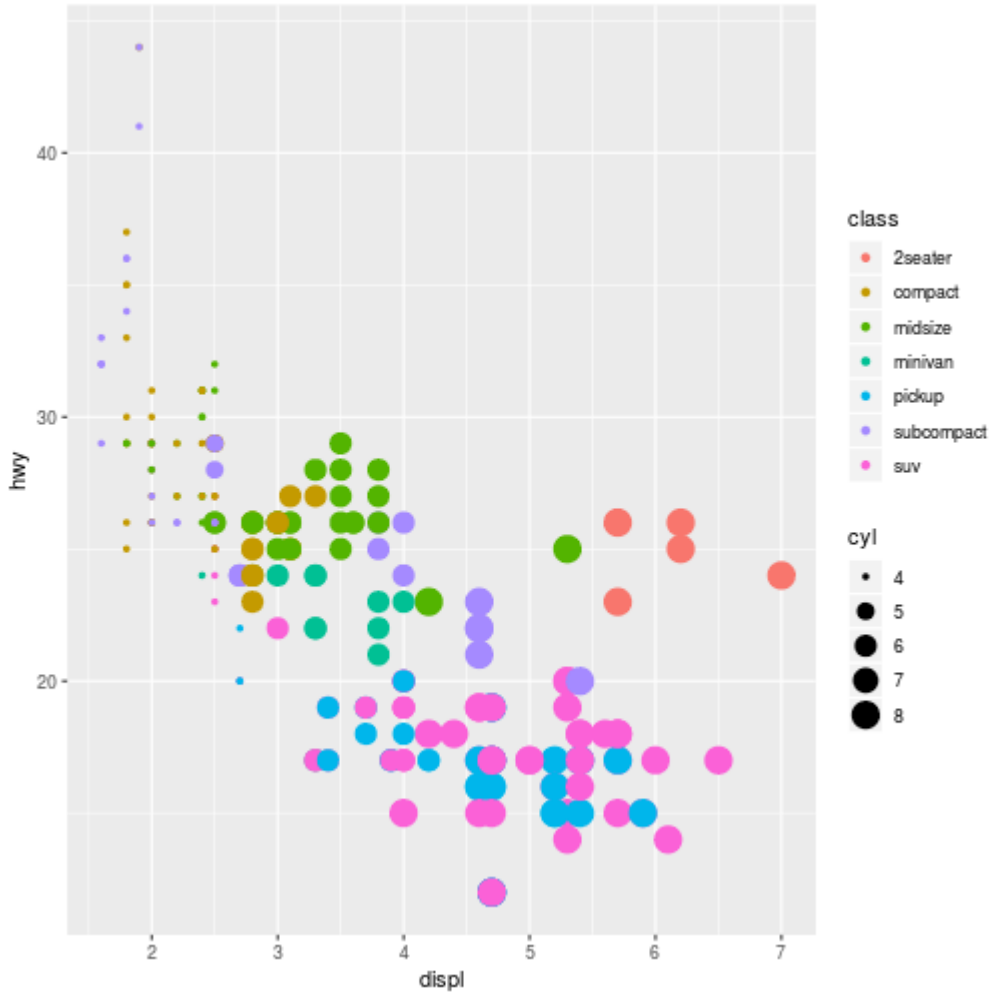

Apariencia del gráfico

- Para cambiar la apariencia del gráfico, se les asigna un valor **manualmente** a las propiedades gráficas anteriores
- **No transmiten información sobre una variable**
- Tienen que estar **fuera** de la función `aes()`

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy), color = "blue", alpha = 0.8, shape
```

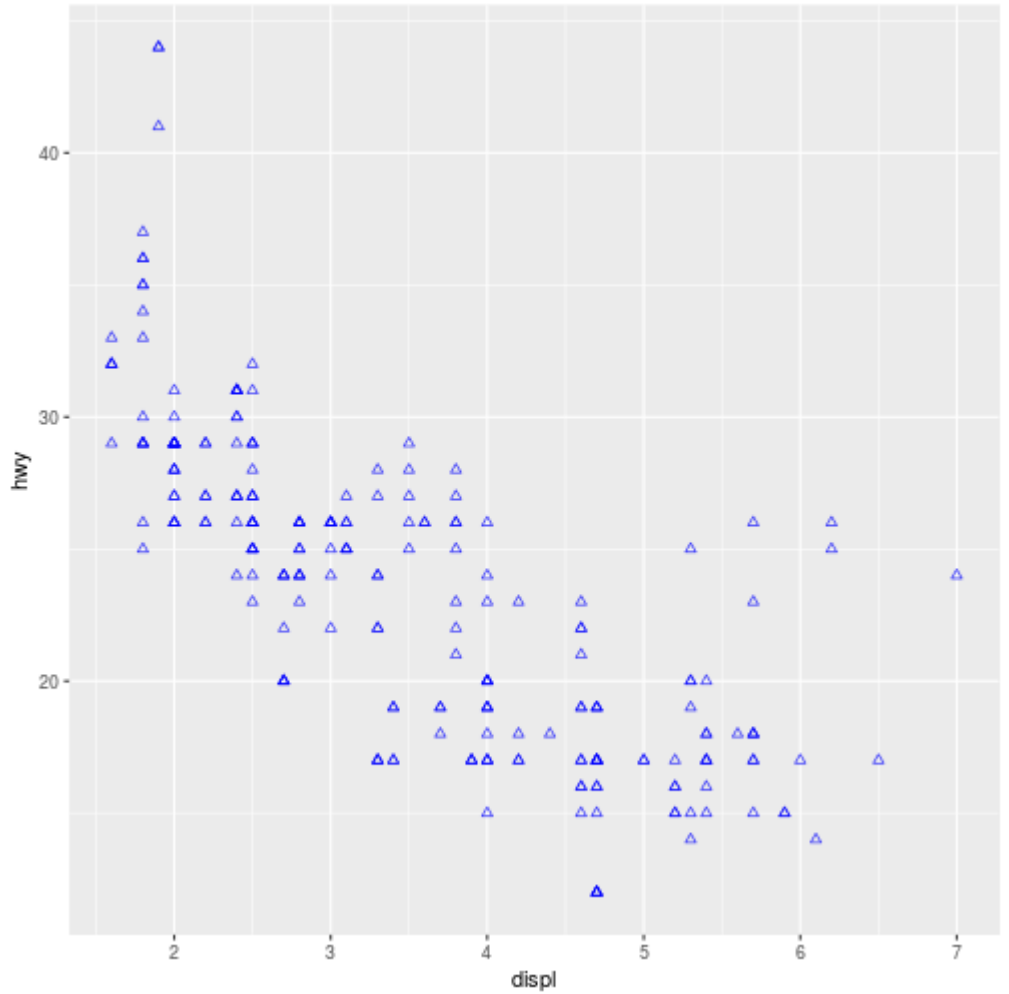

Geoms

- Objectos geométricos que se usan para representar la relación entre las variables `x` e `y`
- Algunos ejemplos son:
  - `geom_bar()`, barras
  - `geom_histogram()`, histograma
  - `geom_density()`, función de densidad
  - `geom_point()`, puntos
  - `geom_line()`, lineas
  - `geom_text()`, texto
  - ...
- Cada `geom` tiene una serie de propiedades gráficas que se pueden asignar a variables o modificar

Geoms (cont.)

One Variable

Continuous

a <- ggplot(mpg, aes(hwy))

a + geom_area(stat = "bin")
x, y, alpha, color, fill, linetype, size
b + geom_area(aes(y = ..density..), stat = "bin")

a + geom_density(kernel = "gaussian"**)**
x, y, alpha, color, fill, linetype, size, weight
b + geom_density(aes(y = ..county..))

a + geom_dotplot()
x, y, alpha, color, fill

a + geom_freqpoly()
x, y, alpha, color, linetype, size
b + geom_freqpoly(aes(y = ..density..))

a + geom_histogram(binwidth = 5**)**
x, y, alpha, color, fill, linetype, size, weight
b + geom_histogram(aes(y = ..density..))

Discrete

b <- ggplot(mpg, aes(fl))

b + geom_bar()
x, alpha, color, fill, linetype, size, weight

Two Variables

Continuous X, Continuous Y

f <- ggplot(mpg, aes(cty, hwy))

f + geom_blank()

f + geom_jitter()
x, y, alpha, color, fill, shape, size

f + geom_point()
x, y, alpha, color, fill, shape, size

f + geom_quantile()
x, y, alpha, color, linetype, size, weight

f + geom_rug(sides = "bl"**)**
alpha, color, linetype, size

f + geom_smooth(model = lm**)**
x, y, alpha, color, fill, linetype, size, weight

f + geom_text(aes(label = cty)**)**
x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

Discrete X, Continuous Y

g <- ggplot(mpg, aes(class, hwy))

g + geom_bar(stat = "identity")
x, y, alpha, color, fill, linetype, size, weight

g + geom_boxplot()
lower, middle, upper, x, ymax, ymin, alpha, color, fill, linetype, shape, size, weight

g + geom_dotplot(binaxis = "y", stackdir = "center"**)**
x, y, alpha, color, fill

g + geom_violin(scale = "area"**)**
x, y, alpha, color, fill, linetype, size, weight

Discrete X, Discrete Y

h <- ggplot(diamonds, aes(cut, color))

h + geom_jitter()
x, y, alpha, color, fill, shape, size

Continuous Bivariate Distribution

i <- ggplot(movies, aes(year, rating))

i + geom_bin2d(binwidth = c(5, 0.5)**)**
xmax, xmin, ymax, ymin, alpha, color, fill, linetype, size, weight

i + geom_density2d()
x, y, alpha, colour, linetype, size

i + geom_hex()
x, y, alpha, colour, fill size

Continuous Function

j <- ggplot(economics, aes(date, unemploy))

j + geom_area()
x, y, alpha, color, fill, linetype, size

j + geom_line()
x, y, alpha, color, linetype, size

j + geom_step(direction = "hv"**)**
x, y, alpha, color, linetype, size

Visualizing error

df <- data.frame(grp = c("A", "B"), fit = 4:5, se = 1:2)
k <- ggplot(df, aes(grp, fit, ymin = fit-se, ymax = fit+se))

k + geom_crossbar(fatten = 2**)**
x, y, ymax, ymin, alpha, color, fill, linetype, size

k + geom_errorbar()
x, ymax, ymin, alpha, color, linetype, size, width (also **geom_errorbarh()**)

k + geom_linerange()
x, ymin, ymax, alpha, color, linetype, size

k + geom_pointrange()
x, y, ymin, ymax, alpha, color, fill, linetype, shape, size

Maps

data <- data.frame(murder = USArrests$Murder, state = tolower(rownames(USArrests)))
map <- map_data("state")
l <- ggplot(data, aes(fill = murder))

l + geom_map(aes(map_id = state), map = map**) + expand_limits(**x = map$long, y = map$lat**)**
map_id, alpha, color, fill, linetype, size

Múltiples geoms

Se pueden mostrar múltiples geoms añadiendo nuevas capas al gráfico:

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  geom_smooth(mapping = aes(x = displ, y = hwy))
```

Ajustes globales

- Se puede configurar el `aes` en la llamada a `ggplot()` y las funciones tipo `geom` tomarán ese `aes` en caso de que no se sobreescriban los atributos del `aes` en la llamada a la función `geom`.

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
  geom_point() +
  geom_smooth()
```

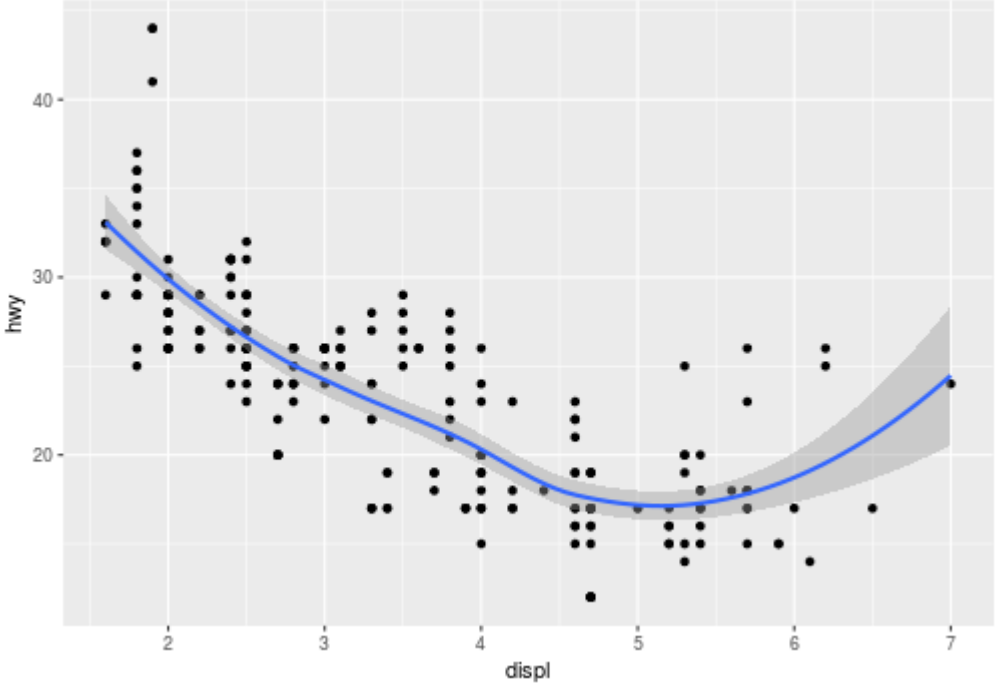

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy, color = drv)) +
  geom_point() +
  geom_smooth()
```

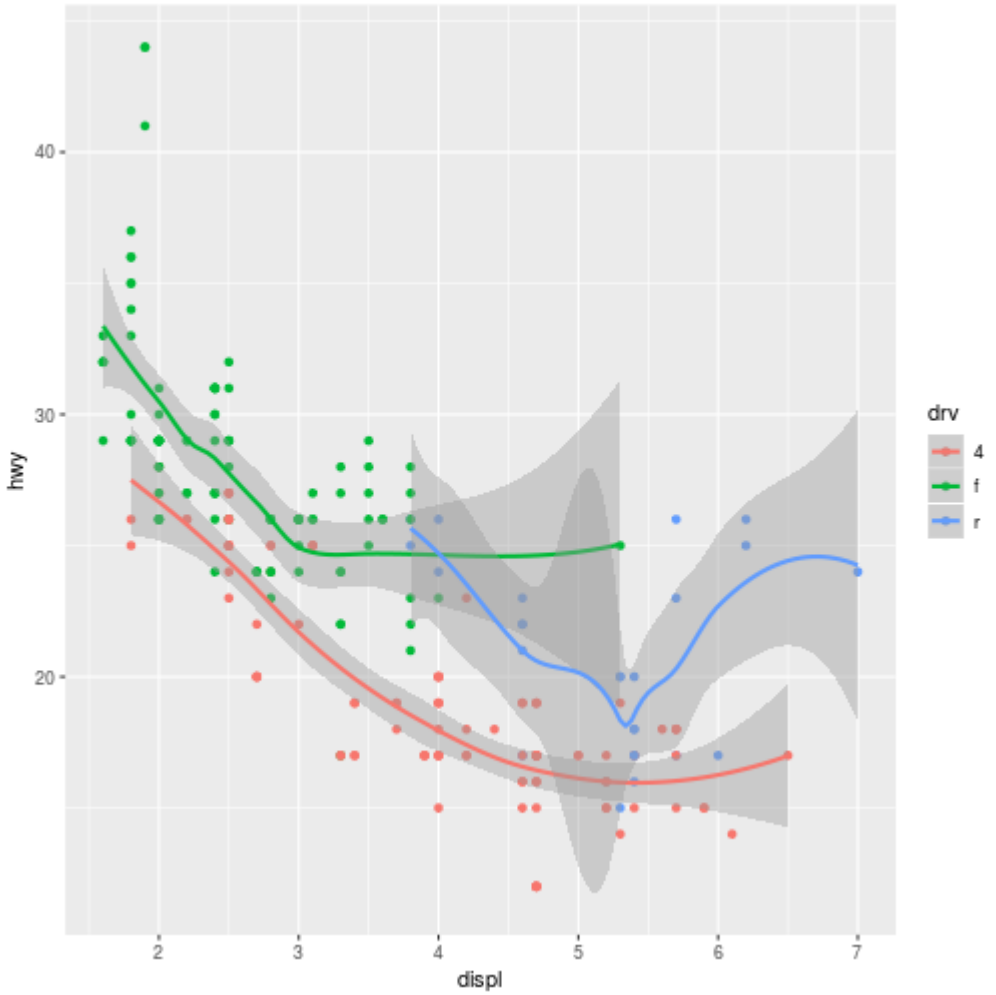

Ajustes locales

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
  geom_point(mapping = aes(color = drv)) +
  geom_smooth(linetype = 2)
```

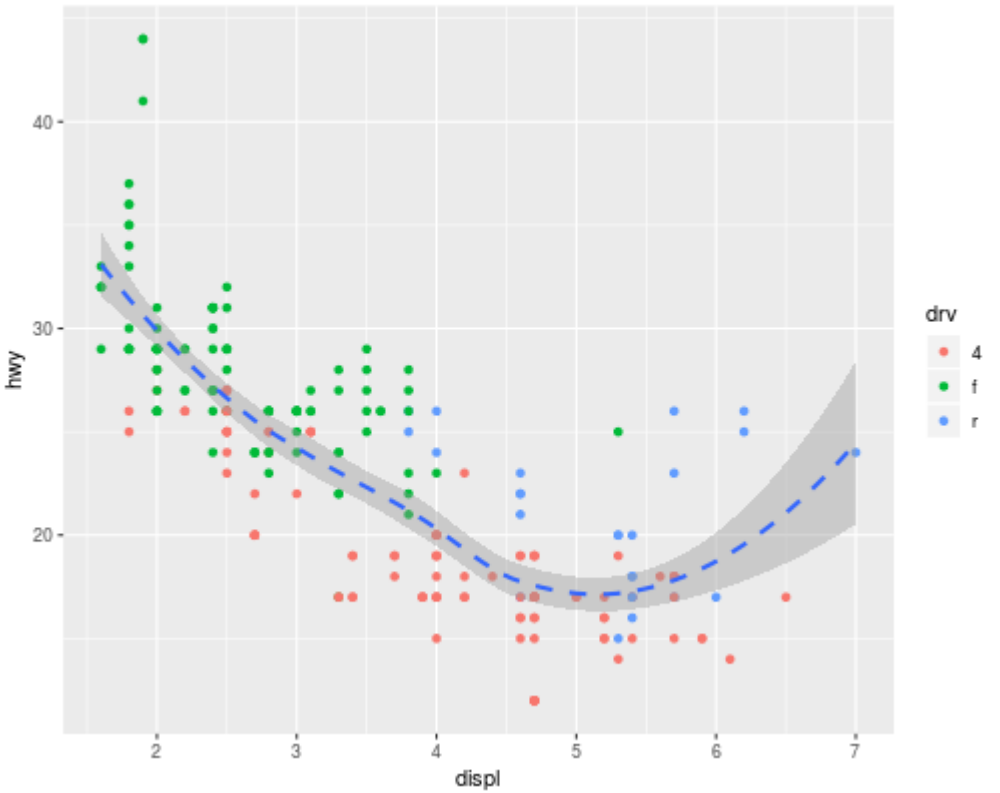

Ajustes locales (cont.)

- También es posible cambiar los datos a representar en un `geom`.

```
mymean <- mpg %>% group_by(displ) %>% summarize(media=mean(hwy))
ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
  geom_point() +
  geom_point(data=mymean,mapping=aes(x=displ,y=media),color="red")
```

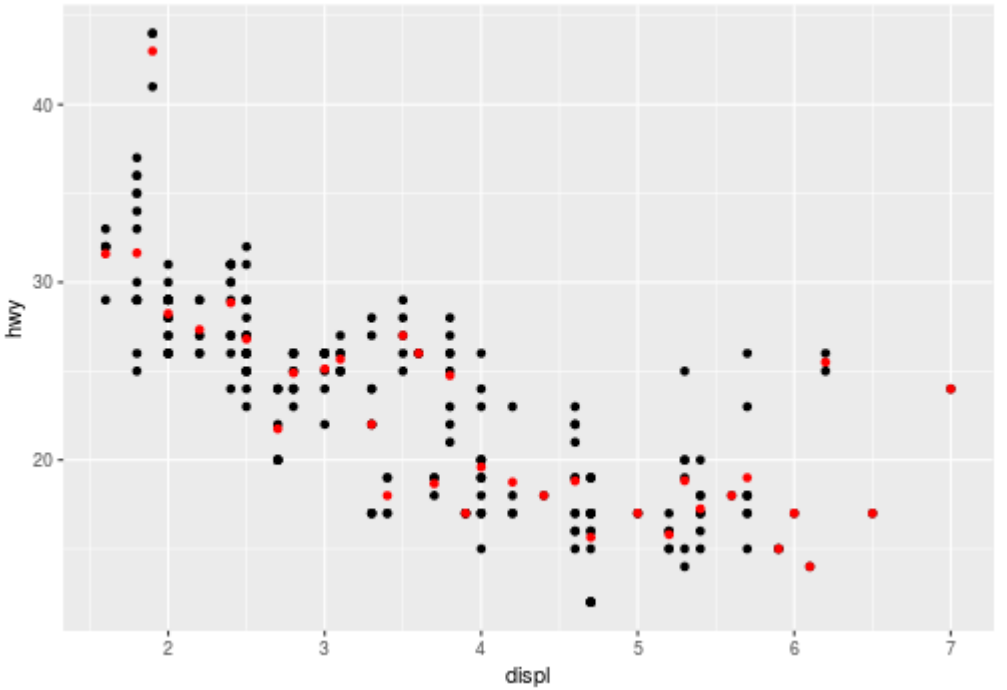

Transformaciones estadísticas

- Algunos `geom` calculan nuevas variables a representar a partir de las originales del data frame.
- Un ejemplo es `geom_smooth()`, que ajusta un polinomio a los datos.
- Para ver la transformación estadística de cada `geom` se puede consultar el valor por defecto del parámetro `stat` en la ayuda.

Ejemplo geom_bar

```
ggplot(data = mpg) +
  geom_bar(aes(x = class))
```

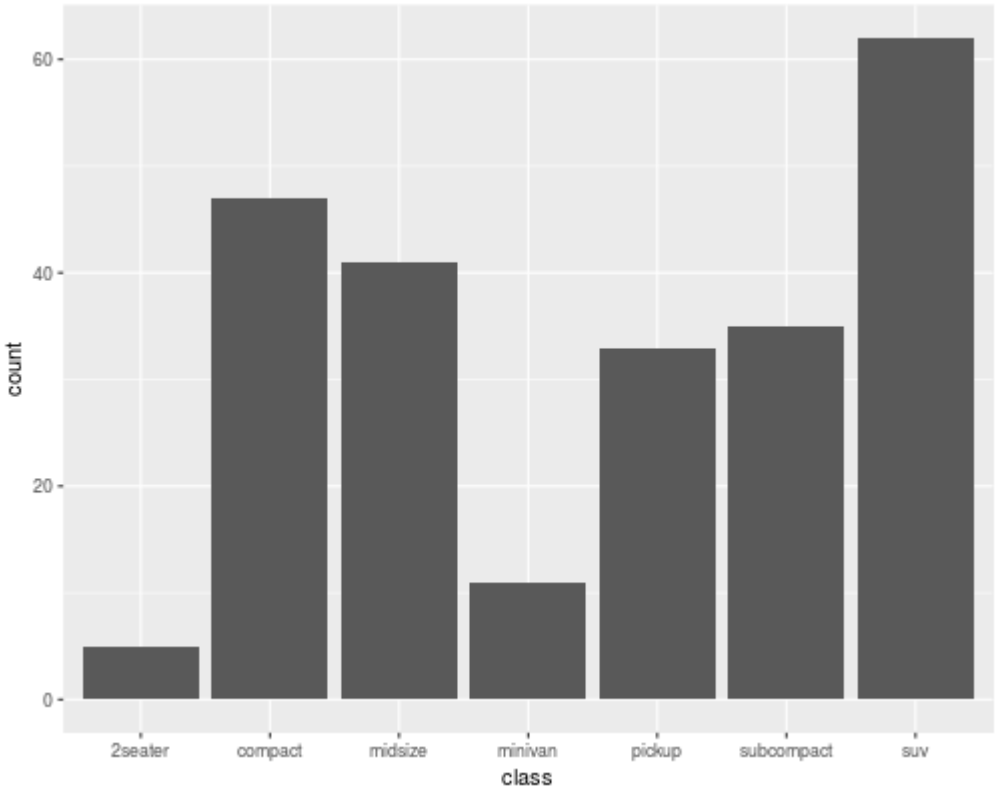

Cambiar stat por defecto

```
n_class <-
  mpg %>%
  group_by(class) %>%
  summarize(n = n())

n_class
```

```
## # A tibble: 7 x 2
##   class          n
##   <chr>      <int>
## 1 2seater        5
## 2 compact       47
## 3 midsize       41
## 4 minivan       11
## 5 pickup        33
## 6 subcompact    35
## 7 suv           62
```

```
ggplot(data = n_class) +
  geom_bar(aes(x = class, y = n), stat = "identity")
```

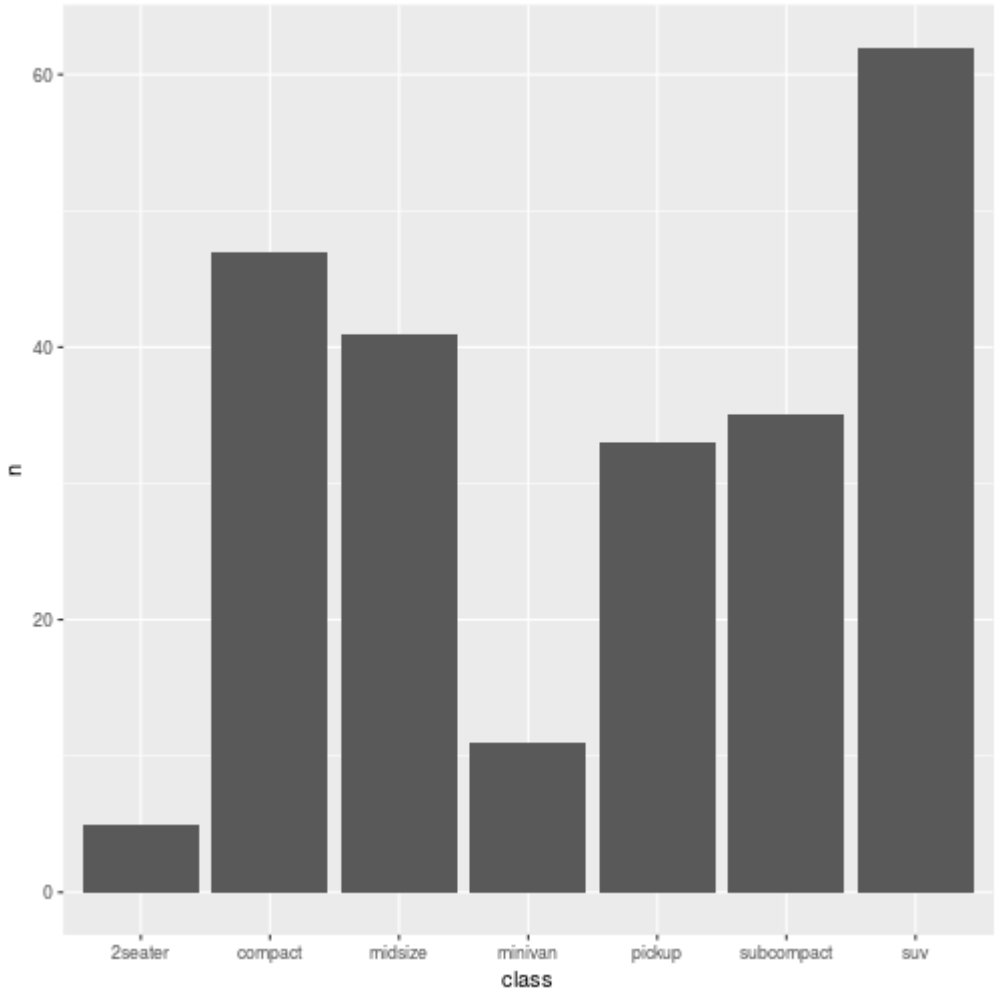

Histograma

- Dada una variable continua:
    - Ordenar sus valores
    - Elegir número de intervalos
    - Contar cuantos valores hay en cada intervalo
    - Representar con barras
- La transformacion estadística se conoce como *binning*.

```
ggplot(data = mpg) +
  geom_bar(mapping = aes(x = hwy), stat = "bin")
```

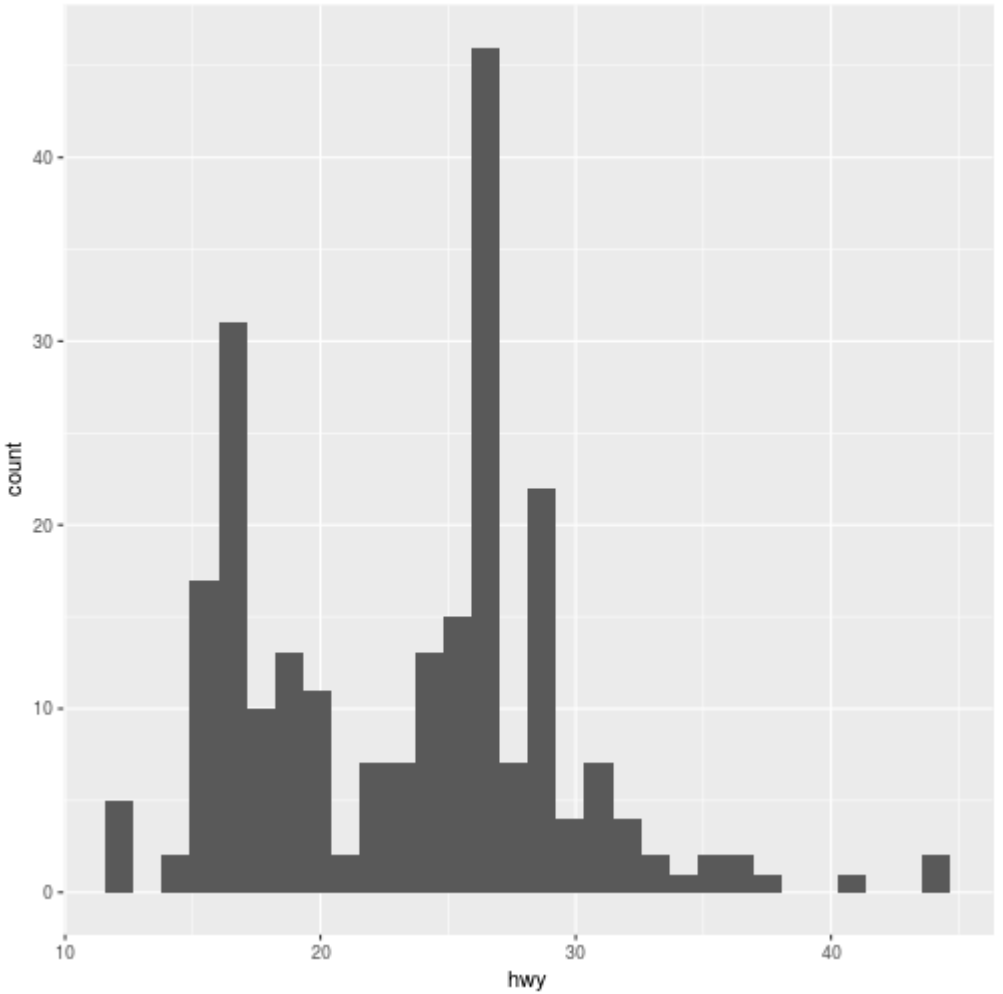

Resultado transformación

Las variables resultado de la transformación son accesibles como `..<NOMBRE>..`

- `..count..`: número de puntos en cada bin
- `..ncount..`: número de puntos en cada bin normalizados por el máximo de conteos sobre todos los bines.
- `..density..`: función de densidad
- `..ndensity..`: función de densidad normalizada por el máximo valor de densidad sobre todos los bines.

```
ggplot(data = mpg) +
  geom_bar(mapping = aes(x = hwy, y = ..density..), stat = "bin")
```

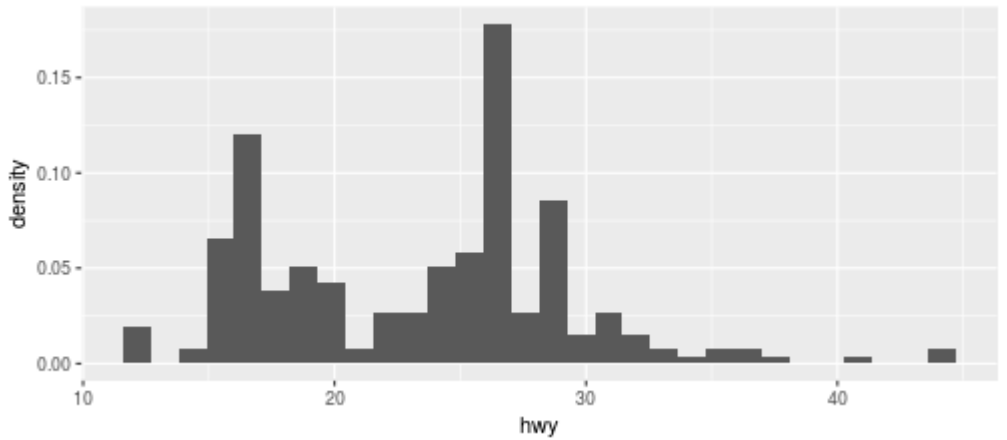

Juntando lo anterior podríamos, por ejemplo, representar un histograma con puntos en vez de barras

```
ggplot(data = mpg) +
  geom_line(mapping = aes(x = hwy, y = ..count..), stat = "bin")
```

geom_histogram

```
ggplot(data = mpg) +
  geom_histogram(mapping = aes(x = hwy))
```

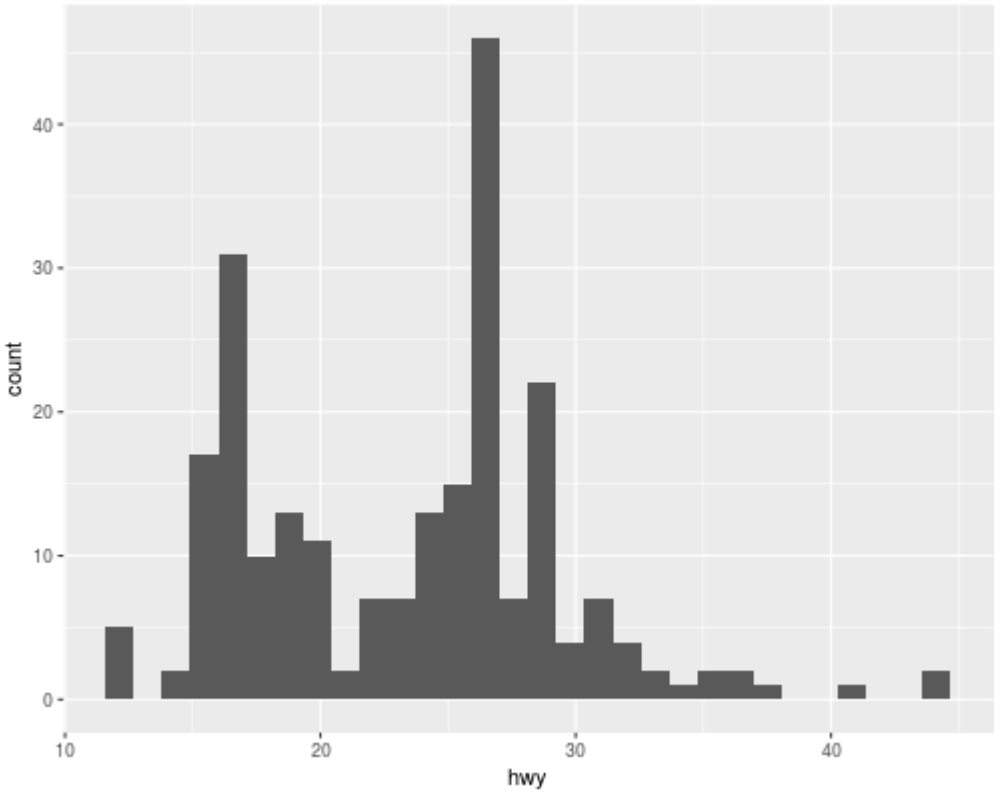

geom_histogram (cont.)

- Generamos el histograma anterior normalizado y en porcentaje.

```
ggplot(data = mpg) +
  geom_histogram(mapping = aes(x = hwy, y=100*..count../sum(..count..)))
```

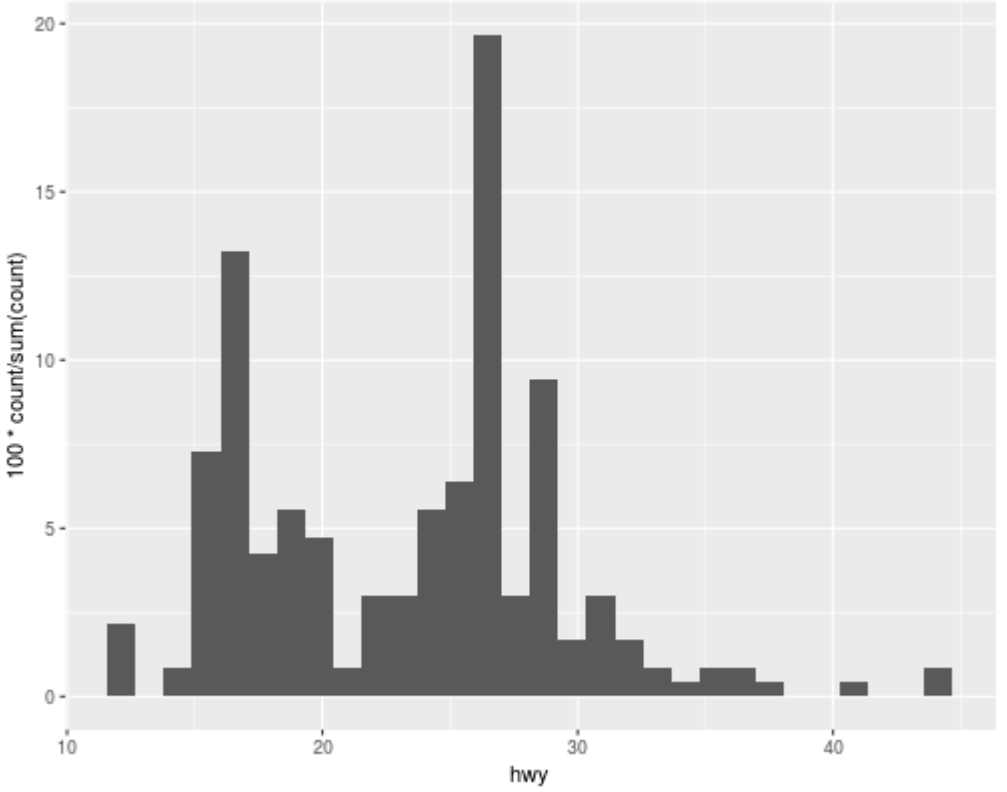

- De forma equivalente:

```
ggplot(data = mpg) +
  geom_bar(mapping = aes(x = hwy, y=100*..count../sum(..count..)),stat="bin")
```

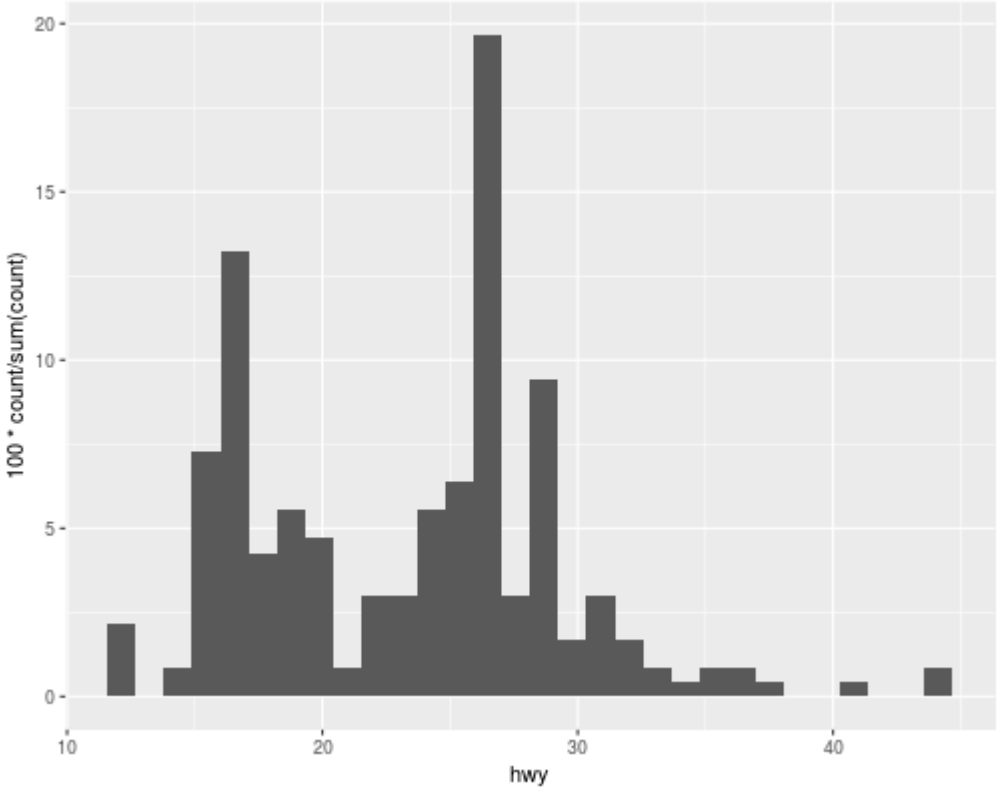

Ajustes de posición

- Ciertos `geom`s tienen un ajuste opcional de posición.
  - En `geom_bar()` su valor por defecto es `stack`.
  - En `geom_point()` su valor por defecto es `identity`.

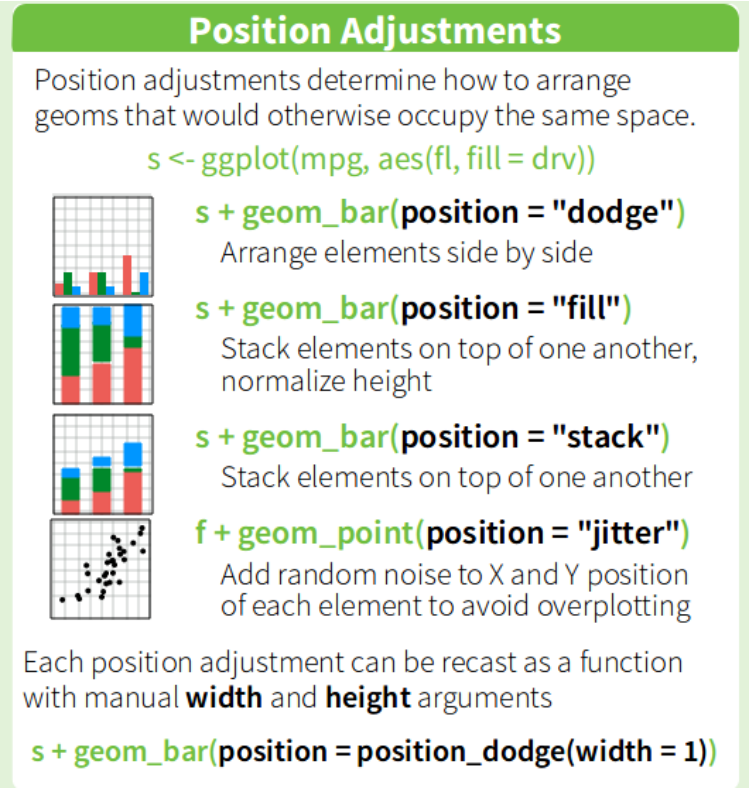

```
ggplot(data = diamonds) +
  geom_bar(mapping = aes(x = cut, fill = color))
```

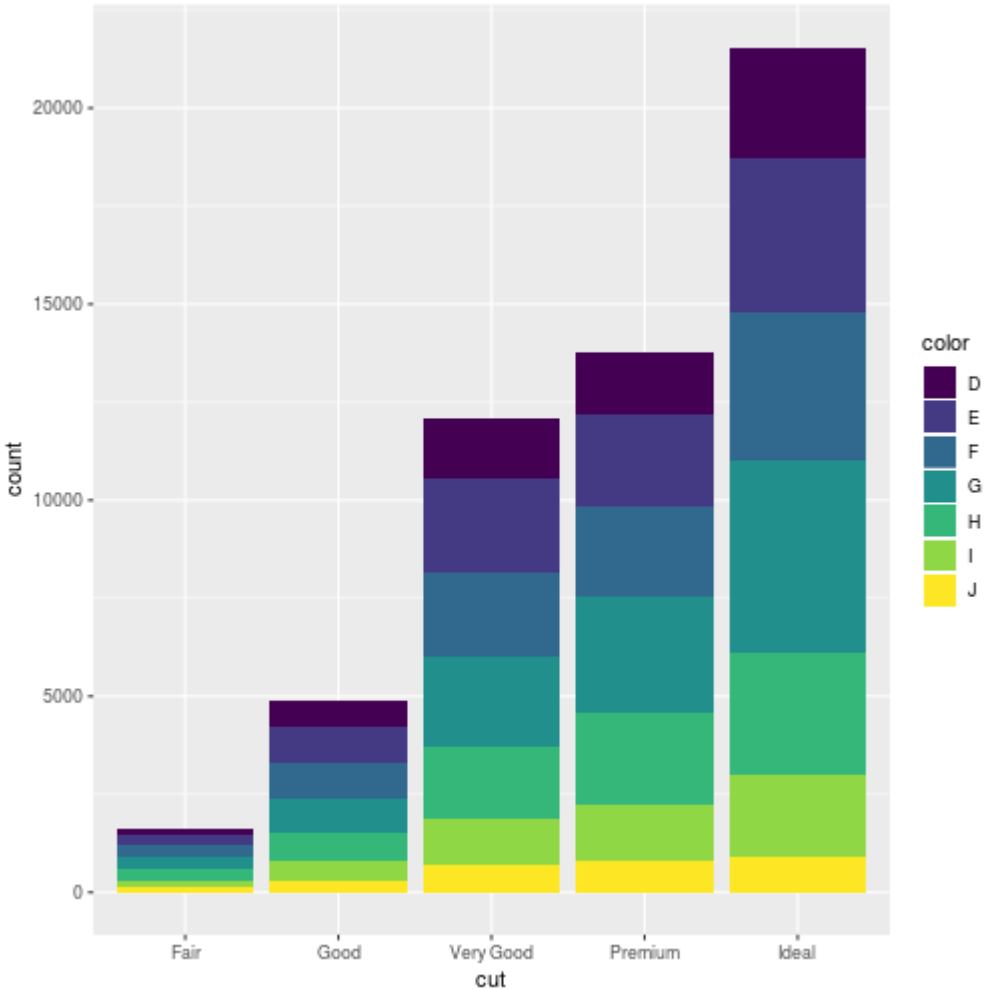

```
ggplot(data = diamonds) +
  geom_bar(mapping = aes(x = cut, fill = color), position = "dodge")
```

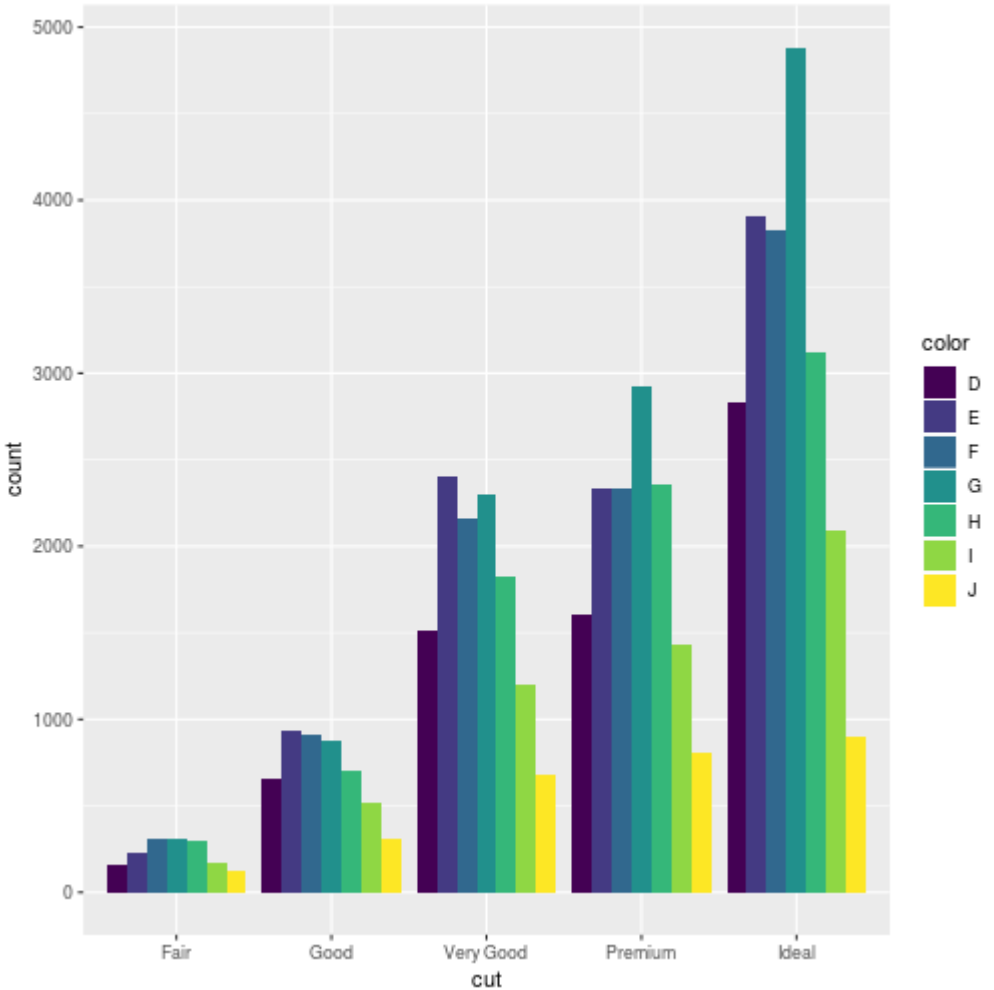

```
ggplot(data = diamonds) +
  geom_bar(mapping = aes(x = cut, fill = color), position = "fill")
```

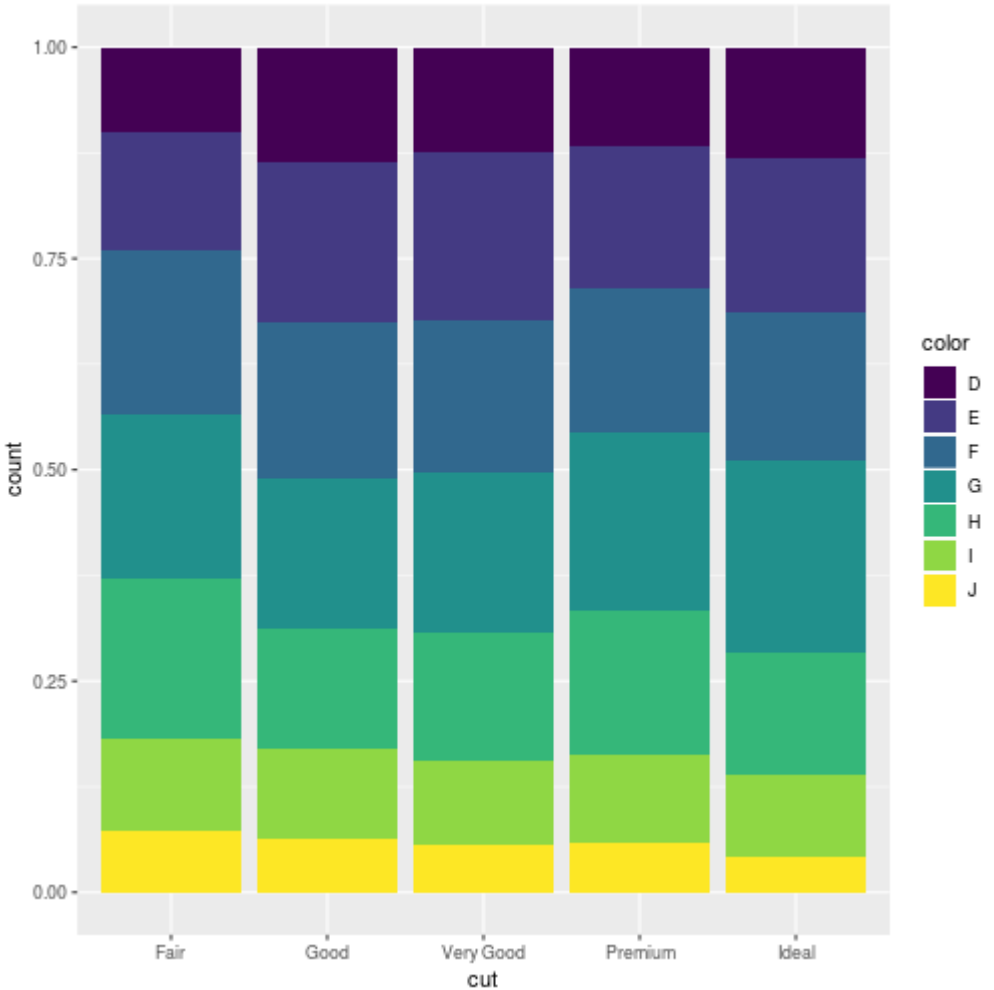

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = cty, y = hwy))
```

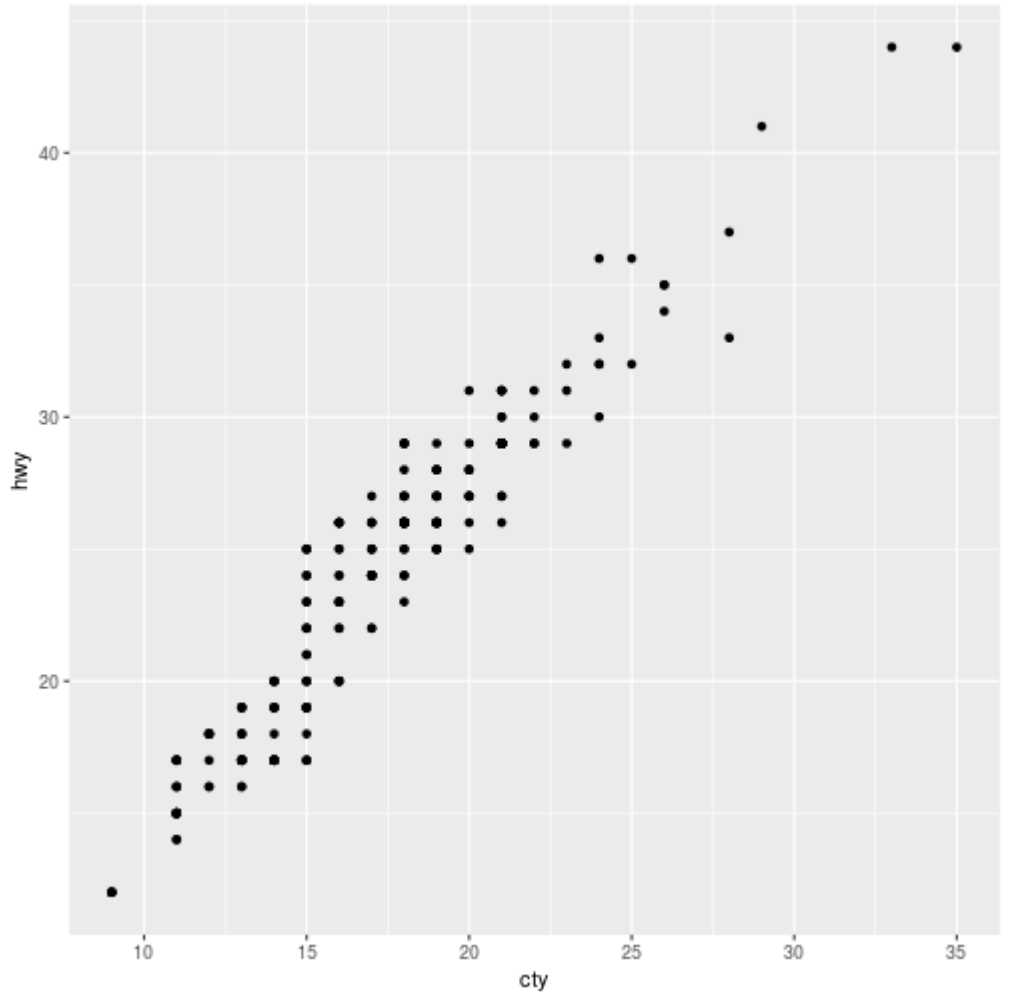

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = cty, y = hwy), position = "jitter")
```