ggplot2

Fundamentos lenguajes: R

Alberto Torres Barrán y Irene Rodríguez Luján

2019-06-21

ggplot2

Introducción

- Implementa una gramática de gráficos en R
- Divide un gráfico en sus componentes esenciales
- Múltiples ventajas con respecto a los gráficos de R base
  - Leyenda automática
  - Facetas
  - ...

Gramática de gráficos

- *mapping* se define con `aes()` (*aesthetics*) y describe como las variables de un data frame se asignan a propiedades visuales
- *data* data frame
- *geom* objetos geométricos con el que se van a representar los datos
- *stat* transforman los datos
- *position* pequeños ajustes en la posición de los elementos

Ejemplo

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy))
```

Plantilla

- El gráfico más sencillo consta como mínimo de los siguientes componentes [Fuente]:

```
ggplot(data = <DATA>) +
  <GEOM_FUNCTION>(mapping = aes(<MAPPINGS>))
```

- Cambiando las secciones entre `<>` se pueden crear múltiples tipos de gráficos
- Añadiendo geoms con el operador `+` se pueden crear gráficos compuestos

Aesthetics

- El gráfico anterior representa dos variables, `displ` y `cyl`
- Variables adicionales se pueden asignar a distintas propiedades del gráfico (*aesthetics*)
- Algunos ejemplos son `color`, `shape`, `size`, `alpha`, etc.
- La escala y la leyenda se crean de forma automática

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, color = drv))
```

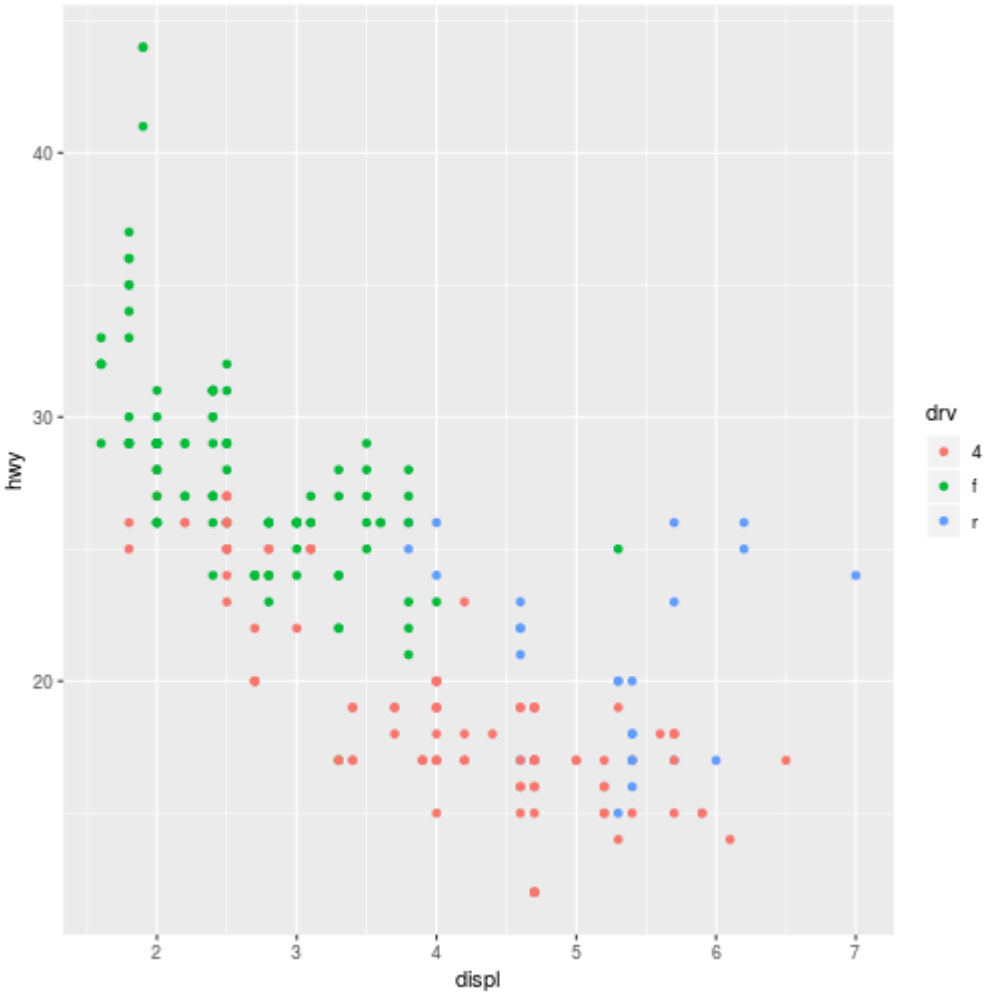

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy, color = class, size =
```

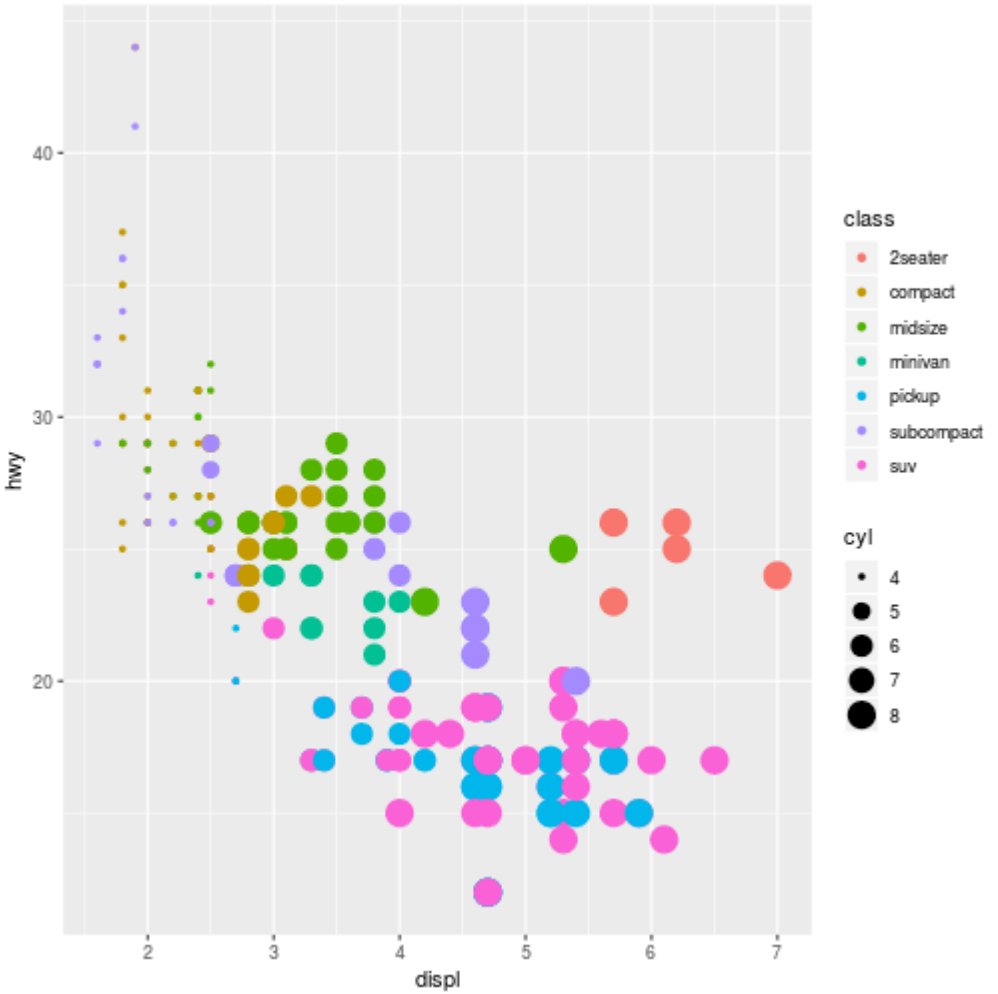

Apariencia del gráfico

- Para cambiar la apariencia del gráfico, se les asigna un valor manualmente a las propiedades gráficas anteriores
- No transmiten información sobre una variable
- Tienen que estar **fuera** de la función `aes()`

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy), color = "blue", alpha
```

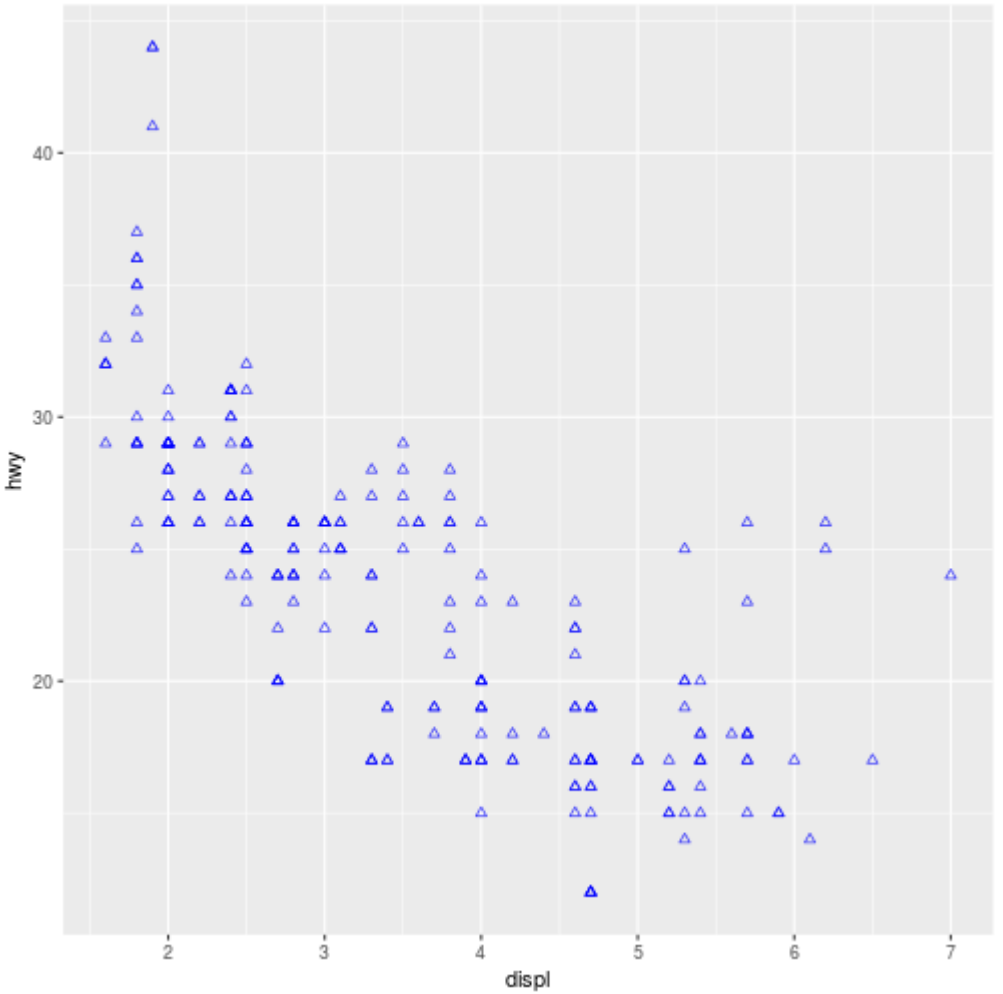

Facets

- Otra opción para representar variables adicionales son las facetas
- Cada faceta es un subgráfico realizado con un subconjunto de los datos

facet_wrap

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  facet_wrap(~drv)
```

facet_grid

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  facet_grid(drv ~ class)
```

Geoms

- Objectos geométricos que se usan para representar la relación entre las variables `x` e `y`
- Algunos ejemplos son:
  - `geom_bar()`, barras
  - `geom_point()`, puntos
  - `geom_line()`, lineas
  - `geom_text()`, texto
  - ...
- Cada `geom` tiene una serie de propiedades gráficas que se pueden asignar a variables o modificar

Múltiples geoms

Se pueden mostrar múltiples geoms añadiendo nuevas capas al gráfico

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = displ, y = hwy)) +
  geom_smooth(mapping = aes(x = displ, y = hwy))
```

Ajustes globales

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
  geom_point() +
  geom_smooth()
```

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy, color = drv)) +
  geom_point() +
  geom_smooth()
```

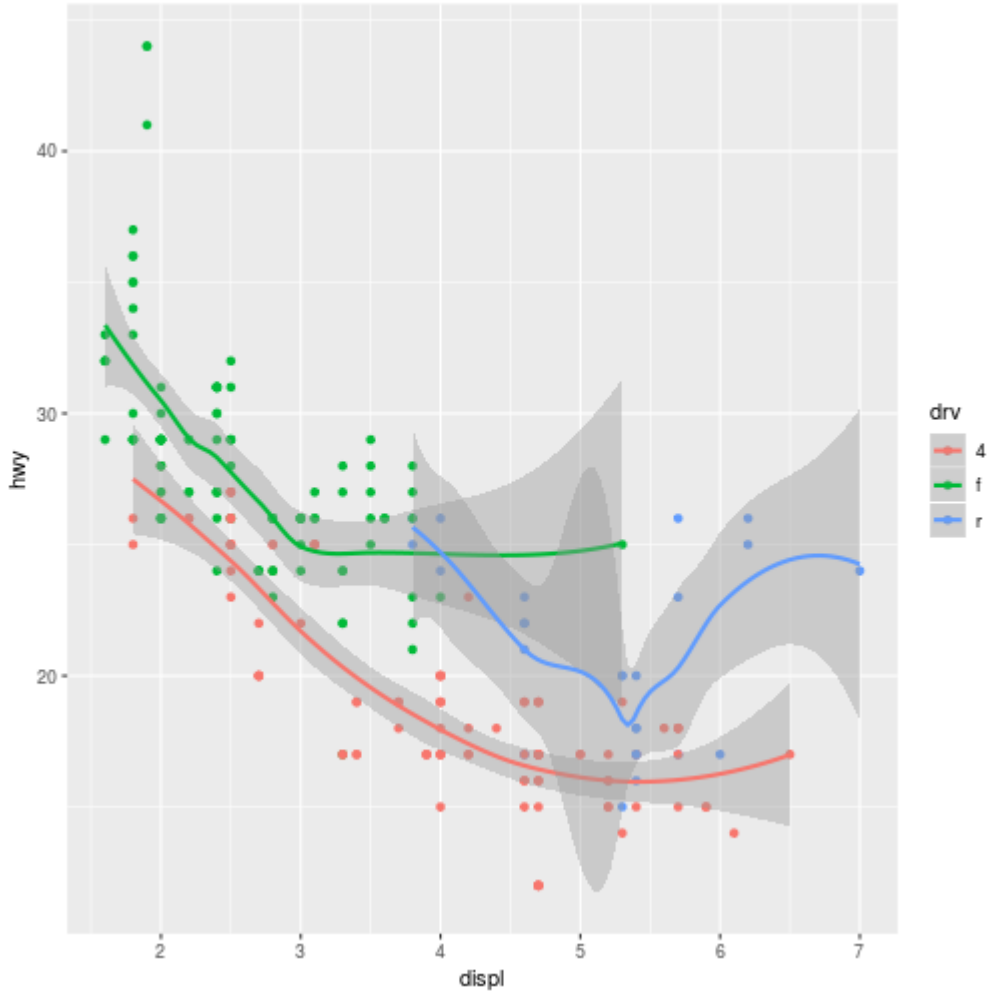

Ajustes locales

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
  geom_point(mapping = aes(color = drv)) +
  geom_smooth(linetype = 2)
```

Transformaciones estadísticas

- Alunos `geom` calculan nuevas variables a representar a partir de las originales del data frame
- Un ejemplo es `geom_smooth()`, que ajusta un polinomio a los datos
- Para ver la transformación estadística de cada `geom` se puede consultar el valor por defecto del parámetro `stat` en la ayuda

Ejemplo geom_bar

```
ggplot(data = mpg) +
  geom_bar(aes(x = class))
```

Cambiar stat por defecto

```
n_class <-
  mpg %>%
  group_by(class) %>%
  summarize(n = n())

n_class
```

```
## # A tibble: 7 x 2
##   class          n
##   <chr>      <int>
## 1 2seater        5
## 2 compact       47
## 3 midsize       41
## 4 minivan       11
## 5 pickup        33
## 6 subcompact    35
## 7 suv           62
```

```
ggplot(data = n_class) +
  geom_bar(aes(x = class, y = n), stat = "identity")
```

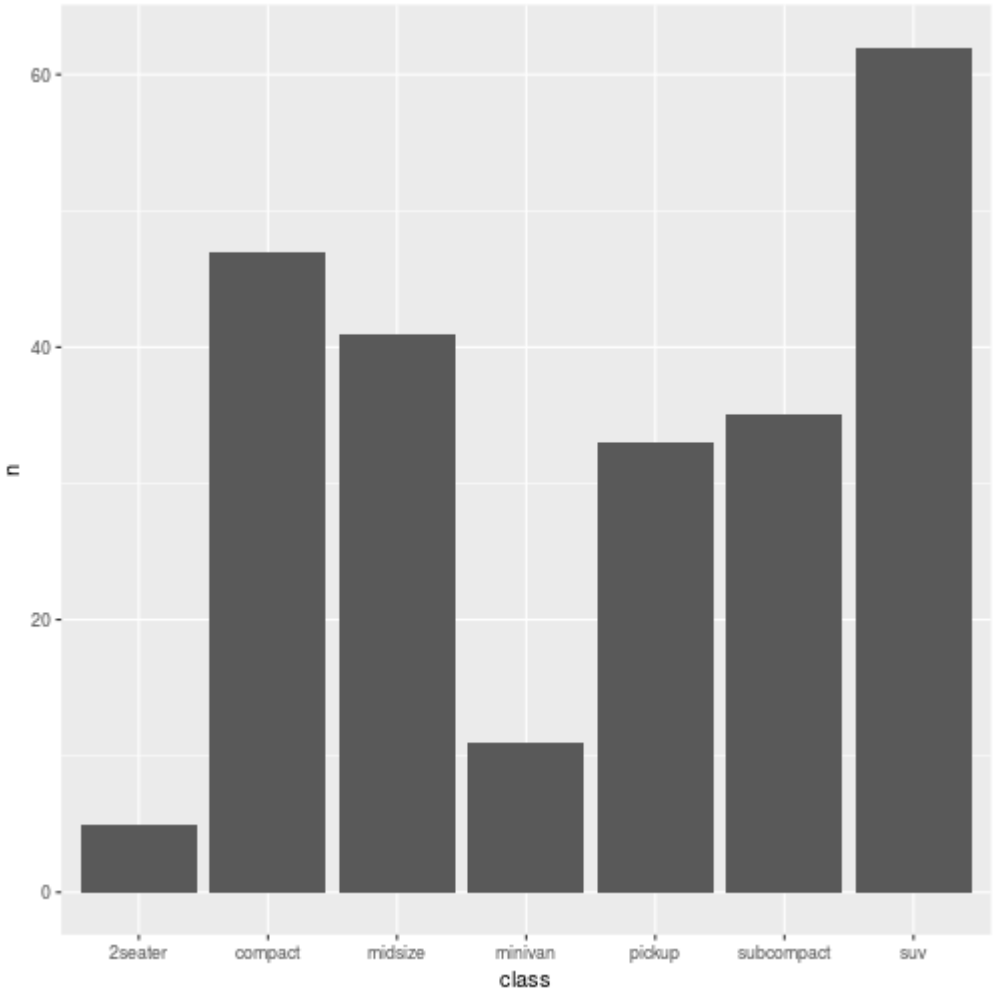

Histograma

- Dada una variable continua:
    - Ordenar sus valores
    - Elegir número de intervalos
    - Contar cuantos valores hay en cada intervalo
    - Representar con barras
- La transformacion estadística se conoce como *binning*

```
ggplot(data = mpg) +
  geom_bar(mapping = aes(x = hwy), stat = "bin")
```

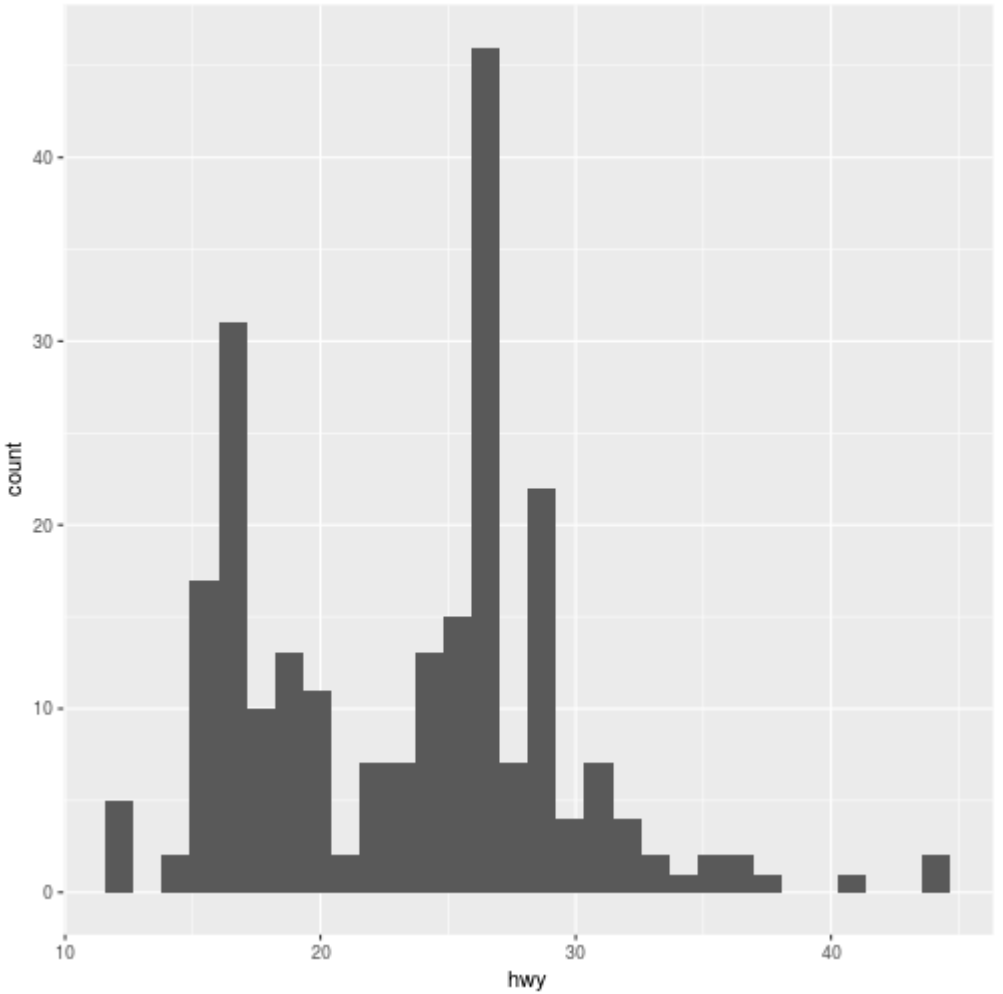

Resultado transformación

Las variables resultado de la transformación son accesibles como `..<NOMBRE>..`

```
ggplot(data = mpg) +
  geom_bar(mapping = aes(x = hwy, y = ..density..), stat = "bin")
```

Juntando lo anterior podríamos, por ejemplo, representar un histograma con puntos en vez de barras

```
ggplot(data = mpg) +
  geom_line(mapping = aes(x = hwy, y = ..count..), stat = "bin")
```

geom_hist

```
ggplot(data = mpg) +
  geom_histogram(mapping = aes(x = hwy))
```

Ajustes de posición

- Ciertos `geom`s tienen un ajuste opcional de posición
- En `geom_bar()` su valor por defecto es `stack`
- Otros ajustes posibles son `dodge` y `fill`
- En `geom_point()` su valor por defecto es `identity`
- Otro valor posible es `jitter`

```
ggplot(data = diamonds) +
  geom_bar(mapping = aes(x = cut, fill = color))
```

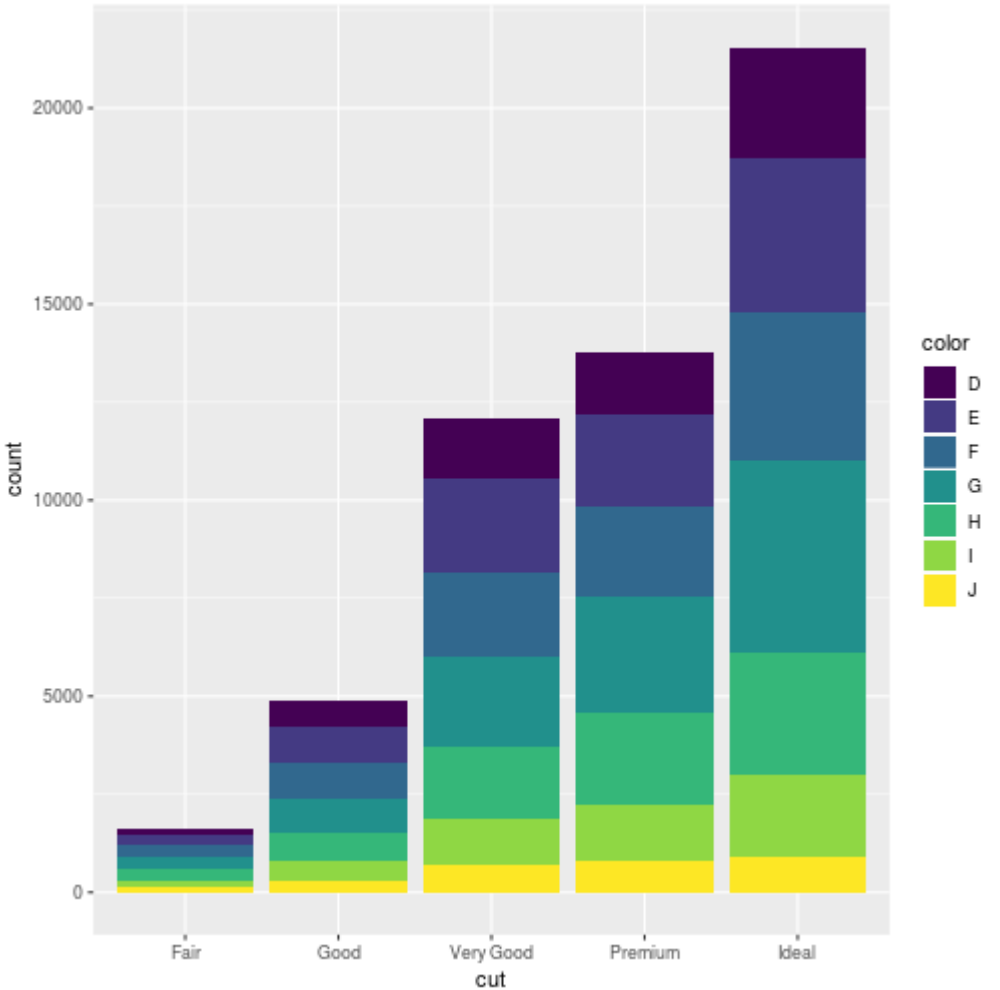

```
ggplot(data = diamonds) +
  geom_bar(mapping = aes(x = cut, fill = color), position = "dodge")
```

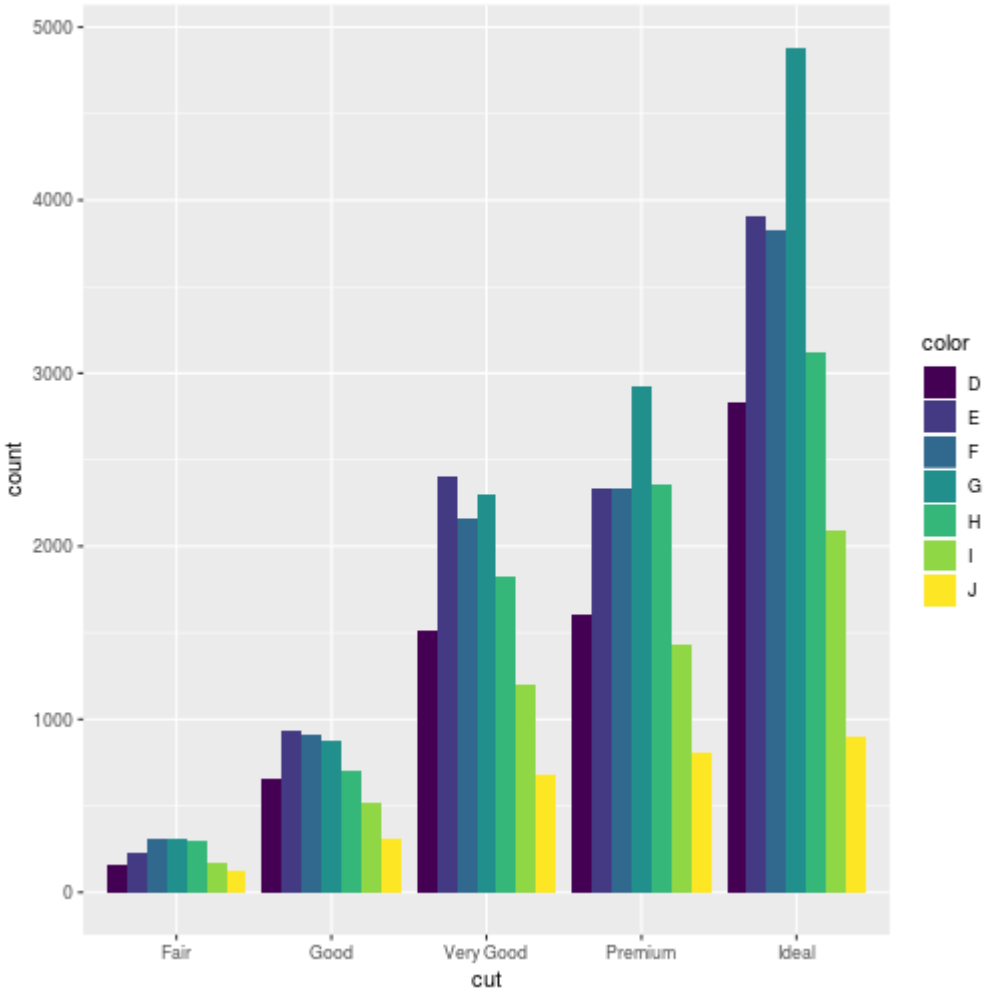

```
ggplot(data = diamonds) +
  geom_bar(mapping = aes(x = cut, fill = color), position = "fill")
```

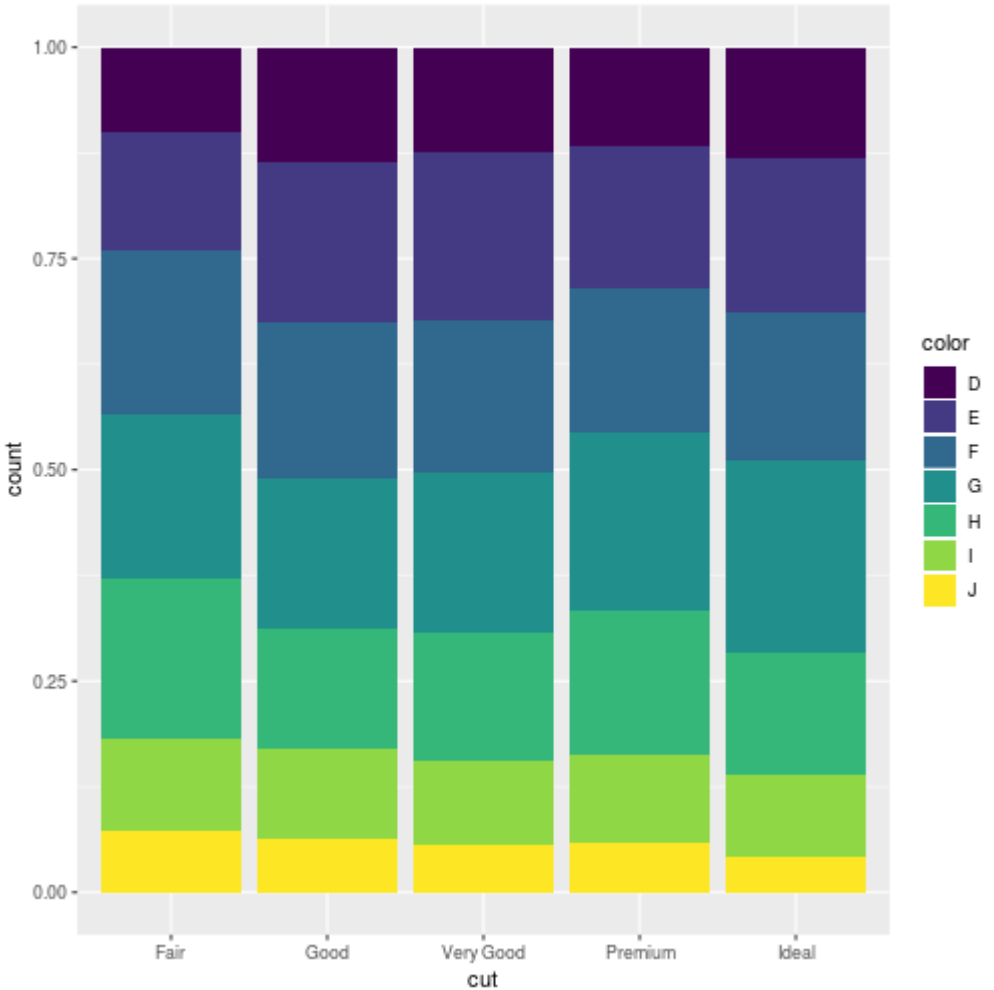

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = cty, y = hwy))
```

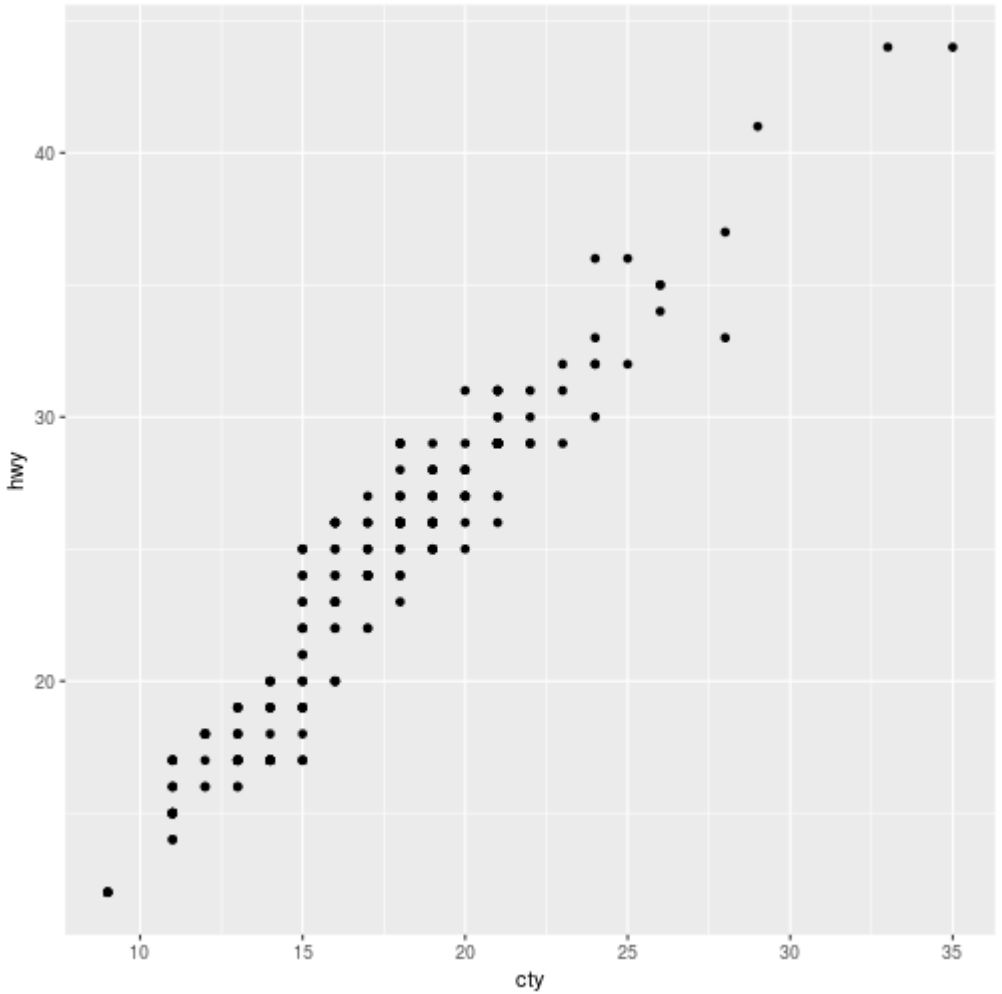

```
ggplot(data = mpg) +
  geom_point(mapping = aes(x = cty, y = hwy), position = "jitter")
```

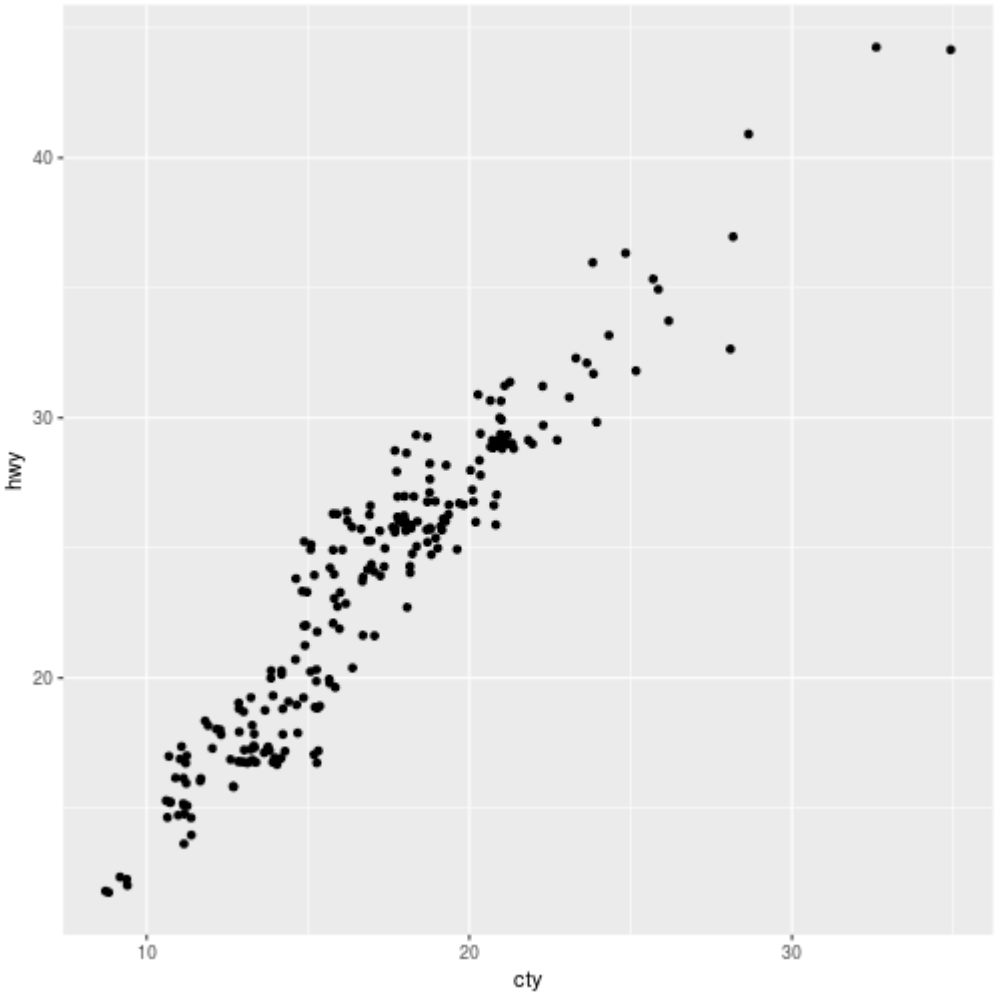

Ejercicio ggplot2

Con el conjunto de datos de diamantes, realizar las siguientes operaciones:

1. Ver cuantas filas (diamantes) y columnas (variables) tiene el conjunto de datos.
2. Hacer un gráfico de barras con la cantidad de diamantes que hay para cada corte (variable cut).
3. Escoger aleatoriamente 10000 diamantes (función `sample_n()`)

La correlación mide la fuerza de una relación lineal entre dos variables. Toma valores entre 0 y ± 1, donde 0 es poca dependencia y 1 máxima dependencia (el signo indica la dirección). En R se calcula con la función `cor()`. Sabiendo lo anterior y sobre la muestra reducida de 10000 diamantes:

1. Hacer un histograma para visualizar la distribución de los precios.
2. Calcular la correlación entre las variables precio y quilates (carat)
3. Visualizar dicha correlación haciendo un gráfico de dispersión del precio sobre los quilates.
4. Repetir el gráfico anterior pero para cada uno de los valores del corte